



پروپوزال پروژه

شماره دانشجویی: ۴۰۱۱۰۲۴۷۸

نام و نام خانوادگی: محمد مختاری

۱. تعریف مسئله پژوهشی

هدف این پروژه، شناسایی و تحلیل عوامل مؤثر بر میزان محبوبیت (Popularity) قطعات موسیقی است. مسئله اصلی پژوهش، درک چگونگی تأثیرگذاری ویژگی‌های ساختاری، صوتی و احساسی یک آهنگ (مانند میزان انرژی، قابلیت رقص‌آوری، سرعت و ارزش عاطفی) بر رفتار شنوندگان و میزان استریم آن در پلتفرم‌های پخش موسیقی است.

۲. بررسی کلی جامعه آماری و نمونه‌گیری

جامعه آماری این پژوهش شامل قطعات موسیقی منتشر شده در پلتفرم اسپاتیفای است. با توجه به گستردگی جامعه، یک نمونه آماری شامل ۱۱۴ هزار قطعه موسیقی از ۱۲۵ ژانر مختلف مورد بررسی قرار می‌گیرد. این حجم بالای نمونه و تنوع ژانری، ضمن تضمین درجات آزادی بسیار بالا، قابلیت تعمیم‌پذیری نتایج را افزایش داده و از تورش‌های مربوط به انتخاب نمونه (Selection Bias) در یک سبک موسیقی خاص جلوگیری می‌کند.

۳. منابع داده‌ای و متادیتا

داده‌های این پژوهش از دیتاست معتبر [Spotify Tracks Dataset](#) استخراج شده از Spotify API (موجود در پلتفرم Kaggle) تأمین می‌شود. ساختار و متادیتای متغیرهای کلیدی مدل به شرح جدول زیر است:

جدول ۱: معرفی متغیرهای مدل پژوهش

نام متغیر	نوع متغیر	توضیحات و نقش در مدل
Popularity	وابسته (Y)	شاخص محبوبیت الگوریتمی اسپاتیفای (عدد صحیح بین ۰ تا ۱۰۰)
Danceability	مستقل (X)	قابلیت رقص‌آوری بر اساس ریتم و تمپو (پیوسته بین ۰ تا ۱)
Energy	مستقل (X)	شدت و فعالیت صوتی آهنگ (پیوسته بین ۰ تا ۱)
Valence	مستقل (X)	ارزش عاطفی و میزان مثبت/شاد بودن آهنگ (پیوسته بین ۰ تا ۱)
Tempo	مستقل (X)	سرعت آهنگ بر حسب BPM (پیوسته)
Loudness	مستقل (X)	میانگین بلندی صدا بر حسب دسی بل (dB)
Explicit	مستقل مجازی	متغیر صفر و یک (Dummy) برای نشان دادن وجود محتوای کلامی نامناسب
Mode	مستقل مجازی	متغیر صفر و یک برای نشان دادن گام آهنگ (۱ = ماژور، ۰ = مینور)
Track_genre	کنترل	متغیر دسته‌ای شامل ۱۲۵ ژانر موسیقی برای کنترل اثرات ثابت گروهی

۴. مسیر انجام پروژه

این مجموعه داده در مجموع شامل ۲۱ ستون است که متشکل از ۱۵ متغیر کمی (پیوسته و گسسته) و ۵ متغیر کیفی (رشته‌ای) می‌باشد.

ابتدا مجموعه داده خام بارگذاری شده و پیش‌پردازش‌های لازم (شامل بررسی و مدیریت مقادیر گمشده و داده‌های پرت) در پایتون انجام می‌گیرد. در مرحله پیش‌پردازش، متغیرهای کیفی نظیر ژانر موسیقی به متغیرهای مجازی (Dummy Variables) تبدیل خواهند شد تا قابلیت ورود به مدل رگرسیون خطی را داشته باشند.

سپس آمار توصیفی متغیرها استخراج می‌شود. در مرحله بعد، مدل رگرسیون چندگانه اولیه با در نظر گرفتن متغیرهای کنترل، تصریح شده و تخمین زده می‌شود. در نهایت، پس از انجام آزمون‌های تشخیصی فروض کلاسیک، مدل نهایی برازش شده و ضرایب، تفسیر اقتصادی و تحلیلی می‌شوند.

۵. بررسی فروض OLS روی داده‌ها و تصریح مدل

با توجه به ماهیت مقطعی (Cross-sectional) داده‌ها، بررسی دقیق فروض کلاسیک رگرسیون خطی (OLS) در این پژوهش حائز اهمیت است:

- عدم هم‌خطی چندگانه (No Perfect Multicollinearity): با توجه به ماهیت متغیرهای

صوتی، احتمال هم‌خطی بین متغیرهایی نظیر انرژی (Energy) و بلندی صدا (Loudness) وجود دارد که با استفاده از ماتریس همبستگی ارزیابی خواهد شد. در صورت وجود هم‌خطی شدید، فرم تابعی تصحیح شده یا یکی از متغیرها حذف می‌گردد.

● **واریانس همسانی (Homoskedasticity):** انتظار می‌رود در سطوح مختلف محبوبیت، پراکندگی خطای مدل متفاوت باشد. این فرض با آزمون‌ها بررسی شده و در صورت رد شدن فرض صفر، از خطاهای استاندارد مقاوم (Robust Standard Errors) استفاده می‌گردد.

● **نرمال بودن توزیع جملات خطا:** با توجه به حجم نمونه بسیار بالا ($n = 114,000$)، بر اساس قضیه حد مرکزی (CLT)، تخمین‌زن‌های OLS همچنان سازگار و دارای توزیع مجانبی نرمال خواهند بود؛ با این حال، توزیع پسماندها در نرم‌افزار رسم و بررسی خواهد شد.

● **تورش متغیرهای حذف شده (OVB):** با وارد کردن متغیر track_genre به عنوان مجموعه‌ای از متغیرهای مجازی (Dummy Variables)، اثرات ثابت (Fixed Effects) ژانرهای مختلف کنترل شده و از بروز تورش در محاسبه ضرایب متغیرهای اصلی جلوگیری می‌شود.